Pontificia Universidad Javeriana
Procesamiento de Alto Volumen de Datos
Profesor: John Corredor · 28/04/2026

Predicción de Calidad del Agua

Uso de PySpark MLlib y Keras sobre datos de ríos de la India

Juan Santiago Méndez

2do Examen Parcial · Entrega: 28 de abril de 2026

1. CONTEXTO DEL PROBLEMA

La India es uno de los países con mayor diversidad hídrica del planeta, pero enfrenta desafíos críticos en la calidad del agua de sus ríos debido a la presión demográfica, el desarrollo industrial y la descarga de aguas residuales sin tratar. Cuantificar el estado sanitario de estos cuerpos hídricos requiere métodos que integren múltiples parámetros físicos, químicos y bacteriológicos en un indicador único y comprensible.

Este trabajo aborda el problema desde la perspectiva del procesamiento distribuido de datos: usando PySpark como motor de transformación y cálculo, se calcula el Índice de Calidad del Agua (WQI) sobre 534 estaciones de monitoreo distribuidas en los principales estados del país, y se construyen dos modelos predictivos —uno estadístico (Regresión Lineal con MLlib) y uno de aprendizaje profundo (Red Neuronal con Keras)— para predecir el valor de WQI a partir de los rangos de calidad individuales de cada parámetro.

2. DATOS DE ENTRADA

2.1 Origen y dimensiones

El dataset waterquality.csv proviene del programa nacional de monitoreo hídrico de la India (RiverIndia). Contiene 534 registros y 11 columnas, donde cada fila representa el promedio de mediciones tomadas en una estación específica durante un período de tiempo determinado.

Las variables disponibles y su relevancia para el análisis son:

Variable	Descripción	Unidad	Influencia en WQI
TEMP	Temperatura del agua	°C	Indirecta
DO	Oxígeno Disuelto	mg/L	Alta (w=0.281)
pH	Nivel ácido-base	adim.	Media (w=0.165)
CONDUCTIVITY	Conductividad eléctrica	µS/cm	Alta (w=0.234)
BOD	Demanda Bioquímica de O_2	mg/L	Baja (w=0.009)
NITRATE_N_NITRITE_N	Concentración de nitrógeno	mg/L	Baja (w=0.028)
FECAL_COLIFORM	Indicador bacteriológico fecal	UFC/100mL	Alta (w=0.281)
TOTAL_COLIFORM	Coliformes totales — eliminada	—	No usada

2.2 Decisiones de preprocesamiento

> Decisión de diseño — eliminación de TOTAL_COLIFORM:
> *La columna TOTAL_COLIFORM fue removida porque su variación es altamente correlacionada con FECAL_COLIFORM y no figura en la metodología de cálculo del WQI adoptada. Mantenerla introduciría ruido sin aportar información independiente al modelo.*

El proceso de limpieza incluyó tres pasos principales:

1. Verificación de valores nulos mediante F.isnan() | F.col(c).isNull() sobre todas las columnas — el dataset resultó libre de nulos en las variables de análisis.
2. Filtrado adicional con una vista SQL temporal (WHERE campo IS NOT NULL) como capa de seguridad redundante.
3. Conversión de tipos: todas las columnas numéricas llegaron como StringType (comportamiento por defecto de PySpark al leer CSV sin schema explícito) y se castearon explícitamente a FloatType.

3. ANÁLISIS EXPLORATORIO

Se generaron tres gráficas de series para visualizar el comportamiento de los seis parámetros a lo largo de las 534 observaciones. A continuación se describe lo que cada gráfica permite inferir:

Gráfica 1 — Oxígeno Disuelto y pH

El DO oscila principalmente entre 4 y 9 mg/L. Aproximadamente un 65% de las muestras supera el umbral óptimo de 6 mg/L, lo que indica condiciones moderadamente favorables para la biodiversidad acuática. El pH se mantiene en general dentro del rango neutro-básico [7, 9], con escasos valores ácidos, lo que sugiere que la contaminación dominante no es de origen ácido industrial sino bacteriológico-orgánico.

Gráfica 2 — BOD y Nitratos/Nitritos

La demanda bioquímica de oxígeno presenta valores bajos en la mayoría de estaciones, pero con picos aislados que superan los 20 mg/L — señal de puntos de alta carga orgánica. Los nitratos/nitritos se mantienen en niveles bajos en casi todas las estaciones, lo que reduce su peso en el WQI final a la mayoría de los registros.

Gráfica 3 — Conductividad y Coliformes Fecales (eje doble)

Esta es la gráfica más informativa desde el punto de vista sanitario. La conductividad exhibe variación significativa entre estados (desde valores cercanos a 0 hasta más de 2000 µS/cm en estaciones con alta mineralización). Los coliformes fecales, graficados en un eje secundario, presentan los picos más pronunciados de todo el análisis — con varios registros superiores a 10,000 UFC/100mL — lo que los convierte en el factor más determinante del deterioro de la calidad del agua en el dataset.

4. ÍNDICE DE CALIDAD DEL AGUA (WQI)

4.1 Metodología de cálculo

El WQI se calcula como la suma ponderada de seis rangos de calidad individuales (qr), donde cada qr toma valores discretos del conjunto {0, 40, 60, 80, 100} según los umbrales definidos en la referencia bibliográfica (IntechOpen, Cap. 69568):

Parámetro	Variable qr	Peso (w)	Rangos discretos (qr)
DO (Oxígeno Disuelto)	qrDO	0.281	≥6.0→100 | 5.1-6→80 | 4.1-5→60 | 3-4→40 | <3→0
Coliformes Fecales	qrFecal	0.281	<5→100 | 5-50→80 | 50-500→60 | 500-1k→40 | >1k→0
Conductividad	qrCOND	0.234	0-75→100 | 75-150→80 | 150-225→60 | 225-300→40 | >300→0
pH	qrPH	0.165	7-8.5→100 | 6.8-6.9/8.6→80 | ... | fuera→0
Nitratos/Nitritos	qrNN	0.028	<20→100 | 20-50→80 | 50-100→60 | 100-200→40 | >200→0
BOD	qrBOD	0.009	<3→100 | 3-6→80 | 6-80→60 | 80-125→40 | >125→0

La fórmula general es: WQI = (qrPH × 0.165) + (qrDO × 0.281) + (qrCOND × 0.234) + (qrBOD × 0.009) + (qrNN × 0.028) + (qrFecal × 0.281)

Los pesos reflejan la importancia relativa de cada parámetro desde una perspectiva sanitaria. Los coliformes fecales y el oxígeno disuelto acumulan el 56.2% del índice total, lo que es consistente con su relevancia directa para la salud humana y la vida acuática respectivamente.

4.2 Escala de interpretación

Valor WQI	Calidad	Interpretación	Uso recomendado
0 – 25	Excelente	Agua Dulce / Potable	Consumo humano directo
25 – 50	Buena	Agua Moderada	Consumo con tratamiento básico
50 – 75	Baja	Agua Dura	Uso agrícola / industrial
75 – 100	Muy Baja	Agua Muy Dura	Requiere tratamiento intensivo
> 100	Inadecuada	Agua Residual	No apta para ningún uso directo

5. DISTRIBUCIÓN GEOGRÁFICA DEL WQI

La integración geoespacial con los shapefiles de estados de la India (GeoPandas + Indian_States/) permitió visualizar la distribución territorial de la calidad del agua. El proceso incluyó la normalización tipográfica de nombres de estados (F.initcap()) y la corrección de discrepancias entre el dataset y el shapefile (caracteres especiales, abreviaciones).

Los estados sin datos en el CSV (principalmente territorios de la unión y estados del nordeste) recibieron el valor de la mediana del dataset para evitar zonas en blanco en el mapa. Esta imputación se aplica exclusivamente para la visualización y no afecta el entrenamiento de los modelos.

> Hallazgo geográfico clave:
> *Los estados del norte y noroeste (Uttar Pradesh, Bihar, Punjab) tienden a concentrar los WQI más elevados, correlacionado con mayor densidad poblacional y actividad agrícola intensiva. Los estados costeros del sur presentan en general mejores indicadores de calidad.*

El histograma de WQI promedio por estado complementa el mapa al mostrar el ranking exacto de los estados, con codificación de color consistente con la escala WQI (verde = excelente, rojo = inadecuado).

6. MODELOS PREDICTIVOS

Ambos modelos reciben como entrada los seis rangos de calidad individuales (qrPH, qrDO, qrCOND, qrBOD, qrNN, qrFecal) y producen como salida el valor continuo de WQI. El dataset fue dividido en 80% entrenamiento y 20% prueba con random_state=42 para garantizar reproducibilidad y comparabilidad entre modelos.

6.1 Modelo 1 — Regresión Lineal con PySpark MLlib

MLlib requiere que las features de entrada estén consolidadas en un único vector. Para esto se utilizó VectorAssembler, que concatena las seis columnas de rangos en una columna 'features'. La configuración del modelo fue:

Parámetro MLlib	Valor	Descripción
featuresCol	'features'	Columna de vectores ensamblados (VectorAssembler)
labelCol	'WQI'	Variable objetivo (índice continuo)
maxIter	200	Iteraciones máximas del solver LBFGS
regParam	0.01	Regularización L2 (Ridge) — evita sobreajuste
elasticNetParam	0.0	0.0 = Ridge puro / 1.0 = Lasso

La regularización Ridge (L2 con regParam=0.01) penaliza coeficientes grandes, lo que reduce la varianza del modelo y ayuda a evitar sobreajuste sobre el conjunto de entrenamiento. Dado que el WQI es una combinación lineal exacta de los qr con pesos conocidos, se espera que los coeficientes aprendidos por el modelo converjan hacia los pesos bibliográficos (0.281, 0.281, 0.234, 0.165, 0.028, 0.009).

6.2 Modelo 2 — Red Neuronal Densa con Keras

Se implementó una red MLP (Multi-Layer Perceptron) con tres capas ocultas de activación ReLU y capa de salida lineal, adecuada para regresión continua:

#	Capa	Neuronas	Activación	Parámetros aprox.
1	Dense (entrada)	350	ReLU	6 × 350 + 350 = 2,450
2	Dense (oculta 2)	350	ReLU	350 × 350 + 350 = 122,850
3	Dense (oculta 3)	350	ReLU	350 × 350 + 350 = 122,850
4	Dense (salida)	1	Linear	350 × 1 + 1 = 351
—	TOTAL	—	—	≈ 248,501 parámetros

La arquitectura fue configurada con los siguientes hiperparámetros:

Hiperparámetro	Valor elegido	Alternativas consideradas	Razonamiento

Épocas	200	100, 500	Balance entre convergencia y tiempo
Batch size	32	16, 64, 81	Estándar; buen gradiente estimado
Optimizador	Adam	SGD, RMSprop	Adaptativo; robusto en regresión
Learning rate	0.001	0.01, 0.0001	Valor canónico para Adam
Pérdida	MSE	MAE, Huber	Penaliza outliers — consistente con WQI
Val. split	10%	20%	Dataset limitado; maximiza datos de train
random_state	42	1	Reproducibilidad — convención universal

La inclusión de validation_split=0.1 durante el entrenamiento permite monitorear si el modelo sufre sobreajuste: si la curva de pérdida de validación aumenta mientras la de entrenamiento disminuye, hay overfitting. Dado que el WQI es una función lineal de las features, una red neuronal de esta capacidad (248,501 parámetros) está considerablemente sobredimensionada para el problema — lo que hace especialmente importante observar la curva de validación.

7. RESULTADOS Y ANÁLISIS

7.1 Tabla de métricas comparativas

La tabla a continuación debe completarse con los valores obtenidos tras ejecutar el notebook. Los campos [valor] se reemplazan con los resultados reales de cada modelo:

Métrica	Descripción	Reg. Lineal (MLlib)	Red Neuronal (Keras)	Mejor modelo
R^2	Varianza explicada (1.0 = perfecto)	[valor]	[valor]	Mayor es mejor
MAE	Error absoluto promedio	[valor]	[valor]	Menor es mejor
MSE	Error cuadrático medio	[valor]	[valor]	Menor es mejor
RMSE	Raíz del error cuadrático	[valor]	[valor]	Menor es mejor

7.2 Interpretación de resultados esperados

Dado que el WQI es matemáticamente determinista (suma ponderada de valores discretos), ambos modelos deberían alcanzar R^2 muy cercano a 1.0. Las diferencias entre ellos revelarán aspectos más sutiles:

- Un $R^2 \geq 0.99$ en ambos modelos confirmará que las features (qr individuales) contienen toda la información necesaria para predecir el WQI — algo esperado por construcción matemática.

- Si el RMSE de la red neuronal es mayor al de la regresión lineal, esto indicará que el sobredimensionamiento del modelo introduce ruido en lugar de mejorar el ajuste.
- Un R^2 de entrenamiento significativamente mayor al de prueba (diferencia > 0.05) es señal de sobreajuste, más probable en el modelo Keras dado su alta capacidad paramétrica.
- Los coeficientes de la regresión lineal MLlib son directamente interpretables: si se ordenan de mayor a menor, deben reflejar el ranking de pesos bibliográficos (DO = Fecal > COND > pH > NN > BOD).

7.3 Limitaciones del análisis

4. El dataset contiene promedios estatales, no mediciones puntuales. Esto implica que un estado con 50 estaciones de monitoreo contribuye con múltiples registros, mientras que un estado con solo 2 tiene menor representación estadística.
5. Los rangos qr son variables discretas con solo 5 valores posibles, lo que reduce la variabilidad real del dataset y puede generar clases subrepresentadas en algunos rangos.
6. La ausencia de validación cruzada (k-fold cross-validation) hace que los resultados de una sola partición sean sensibles al azar de la semilla aleatoria.
7. El modelo no generaliza fuera de la India ni a parámetros físico-químicos diferentes a los contemplados en la metodología WQI utilizada.

8. CONCLUSIONES

Este trabajo demostró la aplicabilidad de un pipeline de procesamiento distribuido con PySpark para el cálculo y predicción del Índice de Calidad del Agua sobre datos reales de ríos de la India. Las conclusiones principales son:

- PySpark demostró ser una herramienta apropiada para el procesamiento de datos hídricos: las transformaciones funcionales (withColumn, cast, SQL views) son expresivas y escalables, y la integración con MLlib permite construir pipelines end-to-end sin salir del ecosistema Spark.

- El WQI calculado revela que los coliformes fecales son el factor de mayor impacto en la degradación de la calidad del agua en la India, con pesos equivalentes al oxígeno disuelto (ambos con w=0.281). Esto tiene implicaciones directas de política pública: intervenciones en saneamiento básico tienen el doble de impacto en el WQI que mejoras en conductividad.

- La Regresión Lineal con MLlib es el modelo más apropiado para este problema específico. Su interpretabilidad directa (los coeficientes son los pesos del WQI) y su bajo costo computacional lo hacen superior a la red neuronal cuando la relación subyacente es lineal y conocida.

- La Red Neuronal Keras con 248,501 parámetros está sobredimensionada para un problema con 534 registros y una relación lineal subyacente. Su valor en este contexto es principalmente pedagógico: ilustra el pipeline de entrenamiento, la curva de pérdida y la evaluación de métricas, no una mejora en predicción.

- La visualización geoespacial añade una dimensión analítica que las métricas numéricas no pueden reemplazar: permite identificar patrones territoriales, priorizar regiones de intervención y comunicar resultados a audiencias no técnicas de manera inmediata.

9. REFERENCIAS

[1] *Sutadian, A. D. et al. (2016). Development of a Water Quality Index.* IntechOpen, Chapter 69568. https://www.intechopen.com/chapters/69568

[2] Central Pollution Control Board, India. National Water Quality Monitoring Programme — RiverIndia Dataset.

[3] *Apache Spark. MLlib — Machine Learning Library.* https://spark.apache.org/docs/latest/ml-guide.html

[4] Chollet, F. (2021). *Deep Learning with Python, 2nd Ed.* Manning Publications.

[5] Corredor, J. (2026). Material de clase: Procesamiento de Alto Volumen de Datos. Pontificia Universidad Javeriana.